

Deep Learning

Ιωάννης Προδρομίδης 1115202200153

January 2026

1 Προετοιμασία και Σύνολο Δεδομένων

Q0.1 Το σύνολο δεδομένων EuroSAT χωρίστηκε με stratified τρόπο, δηλαδή ανά κλάση, ώστε να διατηρείται η ισορροπία μεταξύ των κλάσεων σε όλα τα splits. Για κάθε κλάση, το 70% των δειγμάτων χρησιμοποιήθηκε για το σύνολο Train Full, το 15% για το Validation και το 15% για το Test. Με βάση το Train Full δημιουργήθηκαν επιπλέον δύο few-shot σύνολα: Train 10-shot με 10 εικόνες ανά κλάση και Train 5-shot με 5 εικόνες ανά κλάση.

Η αποφυγή του data leakage διασφαλίστηκε με τον πλήρη διαχωρισμό των indices ανά κλάση πριν τη δημιουργία των splits, καθώς κάθε εικόνα ανήκει αποκλειστικά σε ένα μόνο σύνολο (train, validation ή test). Τα few-shot σύνολα προέρχονται αποκλειστικά από το train set και δεν περιλαμβάνουν δείγματα από τα validation ή test σύνολα.

Q0.2 Για το training χρησιμοποιήθηκαν augmentations που προσομοιώνουν ρεαλιστικές μεταβολές σε δορυφορικές εικόνες χωρίς να αλλοιώνουν τη σημασιολογική πληροφορία. Συγκεκριμένα, εφαρμόστηκε random resized crop για προσομοίωση διαφορετικών κλιμάκων, οριζόντια και κατακόρυφη αναστροφή καθώς και περιστροφή για ενίσχυση της αδιαφορίας ως προς τον προσανατολισμό, που είναι σύνηθες στις δορυφορικές λήψεις. Επιπλέον, χρησιμοποιήθηκε Color Jitter για μικρές μεταβολές φωτεινότητας, αντίθεσης και κορεσμού, προσομοιώνοντας διαφορετικές συνθήκες φωτισμού και ατμόσφαιρας.

Τα augmentations αυτά θεωρούνται κατάλληλα για δορυφορικά δεδομένα, καθώς διατηρούν την κλάση της εικόνας ενώ αυξάνουν τη γενίκευση του μοντέλου. Για τα validation και test σύνολα χρησιμοποιήθηκε μόνο μετατροπή σε tensor, ώστε η αξιολόγηση να γίνεται σε αμετάβλητα δεδομένα.

2 Baseline και Transfer Learning

Q1.1 Το baseline μοντέλο είναι ένα Convolutional Neural Network τεσσάρων επιπέδων συνελίξεων. Συγκεκριμένα, αποτελείται από τέσσερα διαδοχικά convolutional blocks με φίλτρα διαστάσεων 5×5 και αριθμό καναλιών 16, 32, 64 και 128 αντίστοιχα. Κάθε block περιλαμβάνει Batch Normalization, συνάρτηση ενεργοποίησης ReLU και Max Pooling με παράθυρο 2×2 .

Μετά τα convolutional layers, τα χαρακτηριστικά χαρτογραφούνται σε ένα πλήρως συνδεδεμένο τμήμα αποτελούμενο από τέσσερα fully connected layers μεγέθους 1024, 256, 32 και 10, όπου το τελευταίο layer αντιστοιχεί στις 10 κλάσεις του dataset. Μεταξύ των fully connected layers εφαρμόζεται Dropout με πιθανότητα 0.3 για τη μείωση του overfitting.

Q1.2 Κατά την εκπαίδευση του μοντέλου παρατηρείται σταθερή μείωση του training loss και παράλληλη βελτίωση της απόδοσης στο validation set, χωρίς έντονες ενδείξεις overfitting. Το μοντέλο εκπαιδεύτηκε για 10 epochs και το καλύτερο validation F1-score επιτεύχθηκε στο τελευταίο epoch.

Η τελική αξιολόγηση στο test set έδωσε accuracy ίσο με 78.5%, με macro F1-score 0.786, γεγονός που υποδεικνύει ισορροπημένη απόδοση μεταξύ των κλάσεων.

Q1.3 Ο συνολικός χρόνος εκπαίδευσης του baseline μοντέλου ήταν περίπου 261 δευτερόλεπτα για 10 epochs. Το μοντέλο περιλαμβάνει περίπου 2.6 εκατομμύρια trainable παραμέτρους, με το μεγαλύτερο ποσοστό να εντοπίζεται στα fully connected layers. Η σχετικά χαμηλή υπολογιστική πολυπλοκότητα καθιστά το μοντέλο κατάλληλο ως baseline σημείο αναφοράς για σύγκριση με πιο σύνθετες αρχιτεκτονικές.

Μοντέλο	Στρατηγική	Test Accuracy (%)	Training Time (s)	Trainable Params
ResNet18	Full FT	94.77	269.56	~11M
ResNet18	Frozen	75.53	284.63	~0.5M
EfficientNet-B0	Full FT	95.98	396.64	~5.3M
EfficientNet-B0	Frozen	71.34	291.38	~0.4M
ViT-B/16	Full FT	87.12	6874.09	~86M
ViT-B/16	Frozen	84.48	5849.98	--

Πίνακας 1: Αποτελέσματα Transfer Learning με full fine-tuning και frozen backbone

Q1.4

Q1.5 Η καλύτερη επίδοση επιτεύχθηκε από το EfficientNet-B0 με full fine-tuning, το οποίο παρουσίασε test accuracy 95.98%. Η στρατηγική του full fine-tuning υπερίσχυε σταθερά έναντι του frozen backbone, καθώς επέτρεψε την προσαρμογή όλων των επιπέδων του μοντέλου στα χαρακτηριστικά των δορυφορικών εικόνων του EuroSAT. Η αρχιτεκτονική του EfficientNet συνδυάζει αποδοτικά βάθος, πλάτος και ανάλυση, γεγονός που οδήγησε σε υψηλή απόδοση με σχετικά περιορισμένο αριθμό παραμέτρων.

Q1.6 Το freezing του backbone μείωσε σημαντικά τον αριθμό των trainable παραμέτρων, ωστόσο η επίδραση στον συνολικό χρόνο εκπαίδευσης ήταν περιορισμένη, καθώς το forward pass του backbone εξακολουθεί να υπολογίζεται. Παράλληλα, παρατηρήθηκε σημαντική πτώση στην τελική απόδοση, ιδιαίτερα στα CNN-based μοντέλα, γεγονός που δείχνει ότι τα προεκπαιδευμένα ImageNet features δεν επαρκούν από μόνα τους για τη βέλτιστη προσαρμογή στο domain των δορυφορικών εικόνων.

Q1.7 Ο Vision Transformer παρουσίασε χαμηλότερη απόδοση σε σχέση με τα CNN-based μοντέλα, καθώς και δραματικά αυξημένο χρόνο εκπαίδευσης. Παρότι το ViT διαθέτει μεγάλη εκφραστική ικανότητα, απαιτεί μεγαλύτερο όγκο δεδομένων για να αποδώσει ανταγωνιστικά, γεγονός που επηρεάζει αρνητικά τη data efficiency στο EuroSAT. Αντίθετα, τα CNNs εκμεταλλεύονται καλύτερα τις τοπικές χωρικές δομές των εικόνων και παρουσιάζουν καλύτερο trade-off μεταξύ ακρίβειας και υπολογιστικού κόστους στο συγκεκριμένο πρόβλημα.

Μοντέλο	Full Data (%)	10-shot (%)	5-shot (%)
EfficientNet-B0 (Full FT)	95.98	70.44	68.85
ResNet18 (Full FT)	94.77	54.76	38.91

Πίνακας 2: Απόδοση των δύο καλύτερων μοντέλων σε full-data και few-shot σενάρια

Q1.8

Q1.9 Το EfficientNet-B0 αποδείχθηκε πιο data-efficient σε σχέση με το ResNet18, καθώς παρουσίασε μικρότερη πτώση στην απόδοση όταν μειώθηκε δραστικά ο αριθμός των διαθέσιμων δειγμάτων. Συγκεκριμένα, στο 10-shot και 5-shot σενάριο διατήρησε σημαντικά υψηλότερο test accuracy, γεγονός που υποδηλώνει καλύτερη αξιοποίηση των προεκπαιδευμένων χαρακτηριστικών και πιο αποδοτική αρχιτεκτονική σε καθεστώς περιορισμένων δεδομένων.

Q1.10 Στο 5-shot σενάριο παρατηρείται αυξημένη σύγχυση μεταξύ κλάσεων με παρόμοια οπτικά χαρακτηριστικά και χρήσεις γης. Συγκεκριμένα, εμφανίζονται συχνά λάθη μεταξύ των κλάσεων Pasture, PermanentCrop και HerbaceousVegetation, καθώς και μεταξύ Residential και Industrial. Η συμπεριφορά αυτή είναι αναμενόμενη, δεδομένου του εξαιρετικά περιορισμένου αριθμού δειγμάτων ανά κλάση, ο οποίος δεν επιτρέπει στο μοντέλο να μάθει επαρκώς διακριτικά χαρακτηριστικά για οπτικά συγγενείς κατηγορίες.

3 Few-Shot και Zero-Shot Learning

Q2.1 Η cosine similarity απέδωσε καλύτερα από την Euclidean απόσταση και στα δύο few-shot σενάρια. Συγκεκριμένα, στο 5-shot σενάριο η cosine similarity πέτυχε accuracy 41.31% έναντι 34.32% της Euclidean, ενώ αντίστοιχα στο 10-shot σενάριο παρουσίασε accuracy 32.35% έναντι 25.36%. Η υπεροχή της cosine similarity οφείλεται στο ότι εστιάζει στη γωνιακή ομοιότητα των embeddings, μειώνοντας την επίδραση της κλίμακας των διανυσμάτων, κάτι που είναι ιδιαίτερα σημαντικό σε υψηλών διαστάσεων embeddings από προεκπαιδευμένα CNNs.

Support Set	Prototype Classifier (%)	Transfer Learning (%)
5-shot	41.31	68.85
10-shot	32.35	70.44

Πίνακας 3: Σύγκριση prototype-based classifier και transfer learning στα few-shot σενάρια

Q2.2

Q2.3 Το transfer learning αποδίδει σημαντικά καλύτερα από τον prototype-based classifier στο few-shot regime. Παρότι ο prototype-based classifier αξιοποιεί προεκπαιδευμένα embeddings χωρίς fine-tuning, η supervised προσαρμογή των παραμέτρων μέσω transfer learning επιτρέπει στο μοντέλο να ευθυγραμμίσει καλύτερα τα χαρακτηριστικά με το συγκεκριμένο task και τις κλάσεις του EuroSAT, οδηγώντας σε σαφώς ανώτερη απόδοση ακόμη και με ελάχιστα labeled δεδομένα.

Q2.4 Ο prototype-based classifier παρουσιάζει σημαντικά πλεονεκτήματα ως προς την απλότητα και το χαμηλό υπολογιστικό κόστος, καθώς δεν απαιτεί εκπαίδευση και χρησιμοποιεί έναν frozen encoder. Επιπλέον, είναι εύκολα επεκτάσιμος σε νέες κλάσεις με την προσθήκη λίγων δειγμάτων.

Ωστόσο, υστερεί σημαντικά σε απόδοση σε σχέση με το supervised fine-tuning, καθώς δεν προσαρμόζει τα embeddings στο domain των δορυφορικών εικόνων. Η ποιότητά του εξαρτάται άμεσα από τη γενικότητα των προεκπαιδευμένων features, γεγονός που περιορίζει την αποτελεσματικότητά του σε πιο σύνθετα ή domain-specific προβλήματα.

Prompt Strategy	Test Accuracy (%)
Basic prompt	19.07
Domain prompt 1 (aerial view)	0.03
Domain prompt 2 (land use)	12.73
Domain prompt 3 (top-down view)	4.13
Ensemble prompts	7.57

Πίνακας 4: Επίδοση CLIP zero-shot με διαφορετικές στρατηγικές prompts

Q2.5

Q2.6 Το CLIP σε zero-shot ρύθμιση παρουσιάζει σημαντικά χαμηλότερη απόδοση σε σχέση με το καλύτερο configuration του 5-shot transfer learning. Συγκεκριμένα, το CLIP πέτυχε μέγιστο test accuracy 19.07% με το basic prompt, ενώ το EfficientNet-B0 με supervised fine-tuning πέτυχε 68.85% στο ίδιο 5-shot σενάριο. Το αποτέλεσμα αυτό δείχνει ότι ακόμη και ελάχιστα labeled δεδομένα είναι ιδιαίτερα πολύτιμα για την προσαρμογή των μοντέλων στο domain των δορυφορικών εικόνων.

Q2.7 Το CLIP αναγνωρίζει καλύτερα κλάσεις με σαφή και εύκολα περιγράψιμα οπτικά μοτίβα, όπως SeaLake και River, καθώς και ορισμένες εικόνες Residential. Αντίθετα, αποτυγχάνει να διακρίνει αποτελεσματικά κλάσεις όπως AnnualCrop, PermanentCrop, Pasture και HerbaceousVegetation, οι οποίες εμφανίζουν υψηλή οπτική ομοιότητα και των οποίων οι ονομασίες δεν αντιστοιχούν άμεσα σε καθιερωμένες έννοιες του φυσικού λόγου.

Η ανισορροπία στις προβλέψεις υποδηλώνει ότι το CLIP βασίζεται έντονα στη σημασιολογική ευθυγράμμιση εικόνας--κειμένου, η οποία είναι περιορισμένη για εξειδικευμένες κατηγορίες δορυφορικής χρήσης γης.

Q2.8 Σε σενάριο με μηδενικά labeled δεδομένα, το CLIP zero-shot αποτελεί μια άμεση και χαμηλού κόστους λύση, καθώς δεν απαιτεί εκπαίδευση. Ωστόσο, με βάση τα αποτελέσματα, η απόδοσή του στο EuroSAT είναι περιορισμένη. Αν υπήρχε η δυνατότητα απόκτησης έστω και λίγων labeled δειγμάτων ανά κλάση, θα προτιμούσαν η προσέγγιση του self-supervised pretraining σε συνδυασμό με fine-tuning, καθώς επιτρέπει την εκμάθηση domain-specific representations και οδηγεί σε σαφώς ανώτερη απόδοση στο downstream task.

4 Self-Supervised Learning (SimCLR)

Q3.1 Οι τεχνικές data augmentation στο SimCLR διαδραματίζουν καθοριστικό ρόλο, καθώς μέσω αυτών ορίζονται τα θετικά ζεύγη (positive pairs) που χρησιμοποιούνται στο contrastive learning. Εφαρμόζοντας ισχυρούς αλλά ρεαλιστικούς μετασχηματισμούς, όπως random resized crop, οριζόντιο flip, color jitter και Gaussian blur, το μοντέλο μαθαίνει αναπαραστάσεις που είναι αναλλοίωτες σε αλλαγές φωτισμού, κλίμακας και προσανατολισμού. Με αυτόν τον τρόπο αποφεύγεται η εκμάθηση trivial χαρακτηριστικών και ενισχύεται η γενίκευση των learned representations. Χωρίς κατάλληλες augmentations, το contrastive objective χάνει

την αποτελεσματικότητά του και το μοντέλο δεν μαθαίνει ουσιαστική σημασιολογική δομή.

Q3.2 Στον Πίνακα 5 παρουσιάζονται τα αποτελέσματα της σύγκρισης μεταξύ του SimCLR και του ImageNet transfer learning. Για το SimCLR εφαρμόστηκε fine-tuning του encoder στα διαφορετικά data regimes, ενώ το linear evaluation χρησιμοποιήθηκε αποκλειστικά στο full data scenario, σύμφωνα με το standard protocol.


Πίνακας 5: Σύγκριση SimCLR και ImageNet transfer learning

Μέθοδος	Full Data (%)	10-shot (%)	5-shot (%)
SimCLR (linear eval)	N/A	N/A	N/A
SimCLR (fine-tuned)	86.8	83.2	85.3
ImageNet pretrained (best config)	--	--	--

Q3.3 Το self-supervised pretraining με SimCLR στο ίδιο domain (EuroSAT) αποδεικνύεται ιδιαίτερα αποτελεσματικό, ειδικά στα few-shot σενάρια. Οι αναπαραστάσεις που μαθαίνονται είναι περισσότερο προσαρμοσμένες στα χαρακτηριστικά των δορυφορικών εικόνων, γεγονός που οδηγεί σε καλύτερη αξιοποίηση περιορισμένων labeled δεδομένων. Αντίθετα, στο full data regime, το ImageNet transfer learning παραμένει ιδιαίτερα ανταγωνιστικό λόγω της εκπαίδευσης σε πολύ μεγάλης κλίμακας datasets. Συνεπώς, το SimCLR υπερτερεί κυρίως σε low-data regimes, ενώ το ImageNet pretraining διατηρεί πλεονέκτημα όταν υπάρχουν άφθονα labeled δεδομένα.

Q3.4 Η οπτικοποίηση των embeddings του pretrained SimCLR encoder με τεχνικές όπως t-SNE ή UMAP δείχνει ότι κλάσεις με παρόμοια χωρικά και φασματικά χαρακτηριστικά τείνουν να συγκεντρώνονται κοντά στο embedding space. Για παράδειγμα, κατηγορίες όπως residential και industrial παρουσιάζουν μεγαλύτερη επικάλυψη, γεγονός που εξηγεί και τα αντίστοιχα σφάλματα του ταξινομητή. Η συμπεριφορά αυτή είναι αναμενόμενη και υποδεικνύει ότι το SimCLR μαθαίνει μια ουσιαστική σημασιολογική δομή του χώρου δεδομένων.

Q3.6 Το SimCLR προσφέρει τα μεγαλύτερα οφέλη στα few-shot σενάρια (5-shot και 10-shot), όπου η διαθεσιμότητα labeled δεδομένων είναι ιδιαίτερα περιορισμένη. Σε αυτές τις περιπτώσεις, το self-supervised pretraining επιτρέπει στο



Σχήμα 1: Enter Caption

μοντέλο να ξεκινά από ποιοτικές και σταθερές αναπαραστάσεις, μειώνοντας την ανάγκη για μεγάλο αριθμό labels και βελτιώνοντας τη γενίκευση.

Q3.7 Σε ένα σενάριο όπου υπάρχει μεγάλος όγκος unlabeled δορυφορικών εικόνων αλλά ελάχιστα labeled δεδομένα ανά κλάση, η στρατηγική self-supervised pretraining με SimCLR και επακόλουθο fine-tuning ή linear evaluation αποτελεί την καταλληλότερη επιλογή. Η προσέγγιση αυτή αξιοποιεί πλήρως τη διαθέσιμη πληροφορία των δεδομένων χωρίς την ανάγκη εκτενούς χειροκίνητης επισήμανσης, οδηγώντας σε καλύτερη απόδοση σε low-data regimes.

5 LoRA σε Vision Transformer

Q4.1 Στο Task 4 χρησιμοποιήθηκε Vision Transformer προερχόμενο από τη βιβλιοθήκη Hugging Face (μοντέλο `google/vit-base-patch16-224`) και όχι η υλοποίηση του torchvision. Η επιλογή αυτή έγινε διότι το Hugging Face ViT παρέχει σαφή και σταθερά ονόματα στα attention projections (query και value), διευκολύνοντας την ορθή εφαρμογή της τεχνικής LoRA μέσω της βιβλιοθήκης PEFT. Κατά τα λοιπά, η αρχιτεκτονική αντιστοιχεί στο ViT-B/16 που χρησιμοποιήθηκε και στο Task 1.2. Στον Πίνακα 6 παρουσιάζεται η σύγκριση μεταξύ full fine-tuning και LoRA για το Vision Transformer (ViT-B/16). Στην περίπτωση του LoRA, εφαρμόστηκε parameter-efficient fine-tuning με rank $r = 8$ στα attention modules (query και value), ενώ όλες οι υπόλοιπες παράμετροι του backbone παρέμειναν παγωμένες. Η εκπαίδευση πραγματοποιήθηκε στο πλήρες training set για 7 epochs.

Πίνακας 6: Σύγκριση Full Fine-Tuning και LoRA στο ViT-B/16

Μέθοδος	Trainable Params (M)	Trainable Params (%)	Test Accuracy (%)
Full fine-tuning (ViT-B/16)	~86	100%	(Task 1.2)
LoRA ($r = 8$, HF ViT)	~0.15	~0.17%	96.95

Q4.2 Η χρήση του LoRA στο ViT-B/16 οδηγεί σε εξαιρετικά υψηλή απόδοση, με test accuracy 96.95% και macro F1-score 97.01%, παρότι εκπαιδεύεται λιγότερο από το 1% των συνολικών παραμέτρων του μοντέλου. Σε σύγκριση με το full fine-tuning, η ενδεχόμενη πτώση στην ακρίβεια είναι αμελητέα, ενώ το όφελος σε trainable parameters και αποδοτικότητα εκπαίδευσης είναι ιδιαίτερα σημαντικό.

Το αποτέλεσμα αυτό καταδεικνύει ότι το LoRA επιτυγχάνει ένα εξαιρετικό trade-off μεταξύ ακρίβειας και υπολογιστικής αποδοτικότητας.

Q4.3 Η τεχνική LoRA παρουσιάζει σημαντικά πλεονεκτήματα σε δύο βασικά σενάρια. Πρώτον, σε περιβάλλοντα με πολλαπλά downstream tasks, όπου το ίδιο backbone μοντέλο μπορεί να επαναχρησιμοποιηθεί και να προσαρμοστεί σε διαφορετικές εργασίες μέσω ξεχωριστών LoRA adapters, χωρίς την ανάγκη αποθήκευσης πλήρων μοντέλων. Δεύτερον, σε σενάρια με περιορισμούς σε υπολογιστική ισχύ ή μνήμη, όπως περιορισμένα GPU περιβάλλοντα ή edge devices, το LoRA επιτρέπει αποδοτικό fine-tuning μεγάλων μοντέλων με σημαντικά μειωμένο υπολογιστικό κόστος, διατηρώντας παράλληλα υψηλή απόδοση.

6 Συγκριτική Ανάλυση και Συμπεράσματα

Q5.1 Στον Πίνακα 7 παρουσιάζεται συνολική σύγκριση των μεθόδων που εξετάστηκαν στην εργασία. Οι μέθοδοι περιλαμβάνουν κλασικό supervised learning με transfer learning από ImageNet, self-supervised learning με SimCLR, καθώς και parameter-efficient fine-tuning με LoRA σε Vision Transformer. Τα αποτελέσματα συνοψίζουν την απόδοση, την αποδοτικότητα και τις απαιτήσεις εκπαίδευσης κάθε προσέγγισης.

Πίνακας 7: Συνολική σύγκριση μεθόδων

Μέθοδος	Αρχιτεκτονική	Trainable Params	Test Accuracy (%)
ImageNet Transfer Learning	ResNet / ViT	100%	(Task 1)
SimCLR + Fine-tuning (Full data)	ResNet18	100%	86.8
SimCLR + Fine-tuning (10-shot)	ResNet18	100%	83.2
SimCLR + Fine-tuning (5-shot)	ResNet18	100%	85.3
LoRA Fine-Tuning	ViT-B/16 (HF)	~0.17%	96.95

Q5.2 Η συνολική σύγκριση δείχνει ότι διαφορετικές μέθοδοι υπερέχουν σε διαφορετικά σενάρια. Το ImageNet transfer learning προσφέρει ισχυρή baseline απόδοση όταν υπάρχουν επαρκή labeled δεδομένα, ωστόσο απαιτεί πλήρες fine-tuning μεγάλου αριθμού παραμέτρων. Το SimCLR, ως self-supervised μέθοδος, αποδεικνύεται ιδιαίτερα αποτελεσματικό σε low-data regimes, όπου η ποιότητα των

learned representations επιτρέπει ικανοποιητική απόδοση ακόμη και με περιορισμένα labels. Από την άλλη πλευρά, το LoRA στο ViT-B/16 επιτυγχάνει εξαιρετικά υψηλή ακρίβεια με την εκπαίδευση μόνο ενός πολύ μικρού ποσοστού των παραμέτρων του μοντέλου. Το αποτέλεσμα αυτό αναδεικνύει ένα σαφές trade-off μεταξύ αποδοτικότητας και ευελιξίας: το LoRA προσφέρει σχεδόν την ίδια απόδοση με το full fine-tuning, μειώνοντας δραστικά το υπολογιστικό κόστος και τις απαιτήσεις μνήμης.

Q5.3 Σε σενάρια όπου υπάρχουν άφθονα labeled δεδομένα και επαρκείς υπολογιστικοί πόροι, το full fine-tuning ενός pretrained μοντέλου παραμένει μία αξιόπιστη επιλογή. Ωστόσο, όταν τα labeled δεδομένα είναι περιορισμένα αλλά υπάρχει πρόσβαση σε unlabeled δεδομένα του ίδιου domain, το SimCLR αποτελεί ιδιαίτερα ελκυστική λύση, καθώς αξιοποιεί αποτελεσματικά τη διαθέσιμη πληροφορία χωρίς την ανάγκη εκτενούς επισήμανσης. Τέλος, σε περιβάλλοντα με αυστηρούς περιορισμούς σε υπολογιστικούς πόρους ή σε σενάρια πολλαπλών downstream tasks, το LoRA προσφέρει σημαντικά πλεονεκτήματα. Η δυνατότητα προσαρμογής ενός μεγάλου μοντέλου με την εκπαίδευση μόνο ενός μικρού αριθμού παραμέτρων καθιστά τη μέθοδο ιδιαίτερα πρακτική και επεκτάσιμη.

Q5.4 Συνοψίζοντας, η εργασία καταδεικνύει ότι δεν υπάρχει μία ενιαία βέλτιστη προσέγγιση για όλα τα σενάρια. Αντίθετα, η επιλογή της κατάλληλης μεθόδου εξαρτάται από τη διαθεσιμότητα δεδομένων, τους υπολογιστικούς πόρους και τις απαιτήσεις του εκάστοτε προβλήματος. Το SimCLR και το LoRA αναδεικνύονται ως σύγχρονες και ιδιαίτερα αποδοτικές τεχνικές, οι οποίες συμπληρώνουν το κλασικό supervised transfer learning και προσφέρουν ευελιξία και αποδοτικότητα σε πραγματικά εφαρμοσμένα σενάρια.

Q5.5 Το ImageNet transfer learning προτιμάται σε σενάρια όπου υπάρχουν επαρκή labeled δεδομένα και στόχος είναι η ταχεία επίτευξη υψηλής απόδοσης με ελάχιστη προσαρμογή. Τα pretrained μοντέλα στο ImageNet έχουν μάθει γενικά οπτικά χαρακτηριστικά (edges, textures, shapes), τα οποία μεταφέρονται αποτελεσματικά σε πολλά downstream tasks. Ωστόσο, η προσέγγιση αυτή παρουσιάζει περιορισμούς όταν το target domain διαφέρει σημαντικά από το ImageNet, όπως στην περίπτωση των δορυφορικών εικόνων του EuroSAT. Αντίθετα, το self-supervised pretraining στο ίδιο το EuroSAT dataset προτιμάται όταν υπάρχει πρόσβαση σε μεγάλο όγκο unlabeled δεδομένων του domain, αλλά περιορισμένα labels. Το SimCLR επιτρέπει την εκμάθηση αναπαραστάσεων προσαρμοσμένων στα ιδιαίτερα χαρα-

κτηριστικά των δορυφορικών εικόνων, οδηγώντας σε καλύτερη απόδοση σε low-data regimes. Το βασικό μειονέκτημα της προσέγγισης είναι το αυξημένο υπολογιστικό κόστος κατά το pretraining, καθώς και η ανάγκη προσεκτικής επιλογής data augmentations.

Q5.6 Η χρήση του LoRA αξίζει ιδιαίτερα σε σενάρια όπου το μοντέλο είναι μεγάλο και οι υπολογιστικοί πόροι ή η διαθέσιμη μνήμη είναι περιορισμένοι. Μέσω της εκπαίδευσης μόνο ενός μικρού ποσοστού των παραμέτρων, το LoRA επιτρέπει αποδοτικό fine-tuning με ελάχιστη πτώση στην τελική ακρίβεια. Η προσέγγιση αυτή είναι ιδιαίτερα κατάλληλη σε περιβάλλοντα με πολλαπλά downstream tasks, όπου διαφορετικοί LoRA adapters μπορούν να αποθηκευτούν και να εφαρμοστούν στο ίδιο backbone μοντέλο. Το full fine-tuning προτιμάται όταν οι υπολογιστικοί πόροι δεν αποτελούν περιοριστικό παράγοντα και απαιτείται η μέγιστη δυνατή απόδοση. Σε τέτοια σενάρια, η πλήρης προσαρμογή όλων των παραμέτρων επιτρέπει στο μοντέλο να εκμεταλλευτεί πλήρως το training set. Το trade-off μεταξύ accuracy και efficiency κλίνει υπέρ του LoRA όταν η απώλεια ακρίβειας είναι μικρή σε σχέση με το σημαντικό όφελος σε υπολογιστικό κόστος και επεκτασιμότητα, όπως παρατηρήθηκε και στα πειράματα του Task 4.

Q5.7 Με περισσότερο χρόνο ή υπολογιστικούς πόρους, θα ήταν ενδιαφέρον να διερευνηθούν περαιτέρω επεκτάσεις της παρούσας εργασίας. Ενδεικτικά, θα μπορούσε να μελετηθεί η επίδραση διαφορετικών contrastive learning μεθόδων, όπως τα BYOL ή MoCo, και να συγκριθούν με το SimCLR στο ίδιο dataset. Επιπλέον, θα μπορούσε να εξεταστεί η επίδραση διαφορετικών ranks στο LoRA, καθώς και η εφαρμογή του σε περισσότερα layers του ViT.

7 Δήλωση Χρήσης AI Tools

Για την υλοποίηση της παρούσας εργασίας χρησιμοποιήθηκαν εργαλεία τεχνητής νοημοσύνης, και συγκεκριμένα το ChatGPT, με σκοπό την υποστήριξη της διαδικασίας ανάπτυξης και τεκμηρίωσης του έργου.

Συγκεκριμένα, το εργαλείο χρησιμοποιήθηκε: - για αποσφαλμάτωση (debugging) και κατανόηση σφαλμάτων κατά την υλοποίηση των πειραμάτων, - για καθοδήγηση σχετικά με τη λήψη και χρήση pretrained μοντέλων (π.χ. από Hugging Face), - για οδηγίες σχετικά με το πάγωμα (freezing) παραμέτρων μοντέλων και την εφαρμογή τεχνικών fine-tuning, - για βοήθεια στη σωστή προεπεξεργασία και μετατροπή των δεδομένων εισόδου ώστε να είναι συμβατά με το Vision Transformer

(ViT), - για καθοδήγηση στην υλοποίηση του Task 2, το οποίο δεν είχε καλυφθεί προηγουμένως στο πλαίσιο του μαθήματος, - και για υποστήριξη στη σύνταξη και οργάνωση του τελικού PDF με τις θεωρητικές απαντήσεις και τα συμπεράσματα.

8 Πληροφορίες Εκτέλεσης και Πειραματικού Περιβάλλοντος

Χρήση υποσυνόλων δεδομένων Στο πλαίσιο της εργασίας χρησιμοποιήθηκε το dataset EuroSAT. Για την αξιολόγηση της συμπεριφοράς των μοντέλων σε διαφορετικά data regimes, πραγματοποιήθηκαν πειράματα τόσο με το πλήρες training set όσο και με υποσύνολα δεδομένων (few-shot learning). Συγκεκριμένα, εξετάστηκαν τα ακόλουθα σενάρια: - Full Data: χρήση ολόκληρου του διαθέσιμου training set, - 10-shot: χρήση 10 δειγμάτων ανά κλάση, - 5-shot: χρήση 5 δειγμάτων ανά κλάση. Τα υποσύνολα δημιουργήθηκαν με τυχαία δειγματοληψία, διατηρώντας ισορροπία μεταξύ των κλάσεων.

Βασικές βιβλιοθήκες και dependencies Οι κύριες βιβλιοθήκες που χρησιμοποιήθηκαν είναι: - PyTorch - torchvision - transformers - peft - scikit-learn - matplotlib - numpy - torchmetrics

Εκτιμώμενος συνολικός χρόνος εκτέλεσης περίπου 8 ώρες.

Περιγραφή hardware Google Colab Free GPU T4